

생성형 AI와 LLM

체크리스트

- ☑ 기존 소프트웨어(결정적)와 생성형 AI(확률적)의 근본적인 동작 차이를 이해했나요?
- ☑ AI, 머신러닝, 딥러닝, 트랜스포머, LLM의 관계를 설명할 수 있나요?
- ☑ LLM이 문장을 '이해'하는 것이 아니라 '다음 토큰'을 확률적으로 예측한다는 점을 인지하고 있나요?
- ☑ 모든 파라미터가 동작하는 Dense 모델과 일부만 활성화되는 MoE 모델의 차이를 알고 있나요?
- ☑ 토큰(Token) 단위의 과금 체계와 컨텍스트 윈도우(Context Window)의 중요성을 이해했나요?
- ☑ 생성형 AI 활용의 3개 층위(서비스, API/에이전트, 인프라)를 구분하여 설명할 수 있나요?
- ☑ 모델 성능을 객관적으로 비교하기 위해 벤치마크와 리더보드(Arena 등)를 활용하는 법을 알고 있나요?

생성형 AI(Generative AI)란 무엇인가?



기존 소프트웨어

- 사람이 규칙을 직접 작성
- 입력(Input)에 따라 정해진 결과(Output) 반환
- 규칙 밖의 상황에는 약함



생성형 AI

- 대량의 데이터를 학습하여 패턴을 스스로 이해
- 입력을 바탕으로 새로운 결과 생성
- 텍스트, 이미지, 코드, 음성, 영상 등을 생성 가능

대표 사례

텍스트: ChatGPT, Claude, Gemini

이미지: GPT-Image, Nano Banana

코드: Claude Code, Codex

AI에서 LLM까지 (1/2)

1. AI (인공지능)

- 인간의 지능적 행동을 컴퓨터로 구현하려는 분야
- 문제 해결, 추론, 분류, 예측 등을 포함
- 매우 넓은 개념

2. 머신러닝

- 사람이 규칙을 직접 작성하지 않고 데이터를 통해 학습
- 데이터 패턴을 기반으로 결과를 예측
- 스팸 필터, 추천 시스템 등에 사용

3. 딥러닝

- 머신러닝의 한 종류
- 인공신경망을 깊게 쌓아 복잡한 패턴 학습
- 이미지 인식, 음성 인식, 자연어 처리에서 큰 성능 향상

인공신경망(Neural Network)

인간 뇌의 뉴런 연결 구조를 단순화하여 모방한 모델.

입력 데이터를 여러 층(layer)을 거치며 처리.

AI에서 LLM까지 (2/2)

4. 트랜스포머 (Transformer)

- 현재 생성형 AI 시대를 만든 핵심 구조
- 2017년 Google 논문 "Attention Is All You Need" 제안
- 문장 전체의 관계와 맥락을 동시에 파악 가능
- 기존 RNN/LSTM 구조보다 병렬 처리에 강함
- GPT, Claude, Gemini 대부분이 기반

컨텍스트 (Context)

현재 대화나 문서에서 모델이 참고하는 맥락 정보. 이전 대화, 문서 내용, 지시사항 등이 포함된다.

5. LLM (Large Language Model)

- 거대한 규모의 언어 모델
- 인터넷 문서, 책, 코드 등을 대량 학습
- 자연어 이해와 생성에 특화
- 질문 답변, 번역, 요약, 코드 생성 등을 수행

언어 모델 (Language Model)

다음 단어를 예측하는 방식으로 언어를 학습한 모델. 문장을 이해하는 것이 아니라 확률적으로 가장 그럴듯한 다음 토큰을 예측한다.

대표적인 LLM 분류

상용/폐쇄형 (Proprietary)

- OpenAI - GPT
- Anthropic - Claude
- Google - Gemini

상용/폐쇄형 모델

모델 가중치(weights), 학습 데이터, 내부 구조가 공개되지 않은 모델. 보통 API 또는 공식 서비스 형태로 제공되며, 모델 자체를 직접 수정·재배포·자체 호스팅하기 어렵다.

오픈웨이트/로컬 (Open-weight/Local)

- GPT-OSS / Gemma / Llama
- Deepseek / Kimi / Qwen / GLM

오픈웨이트 모델

학습된 모델 가중치(weights)가 공개된 모델. 사용자가 직접 다운로드하여 수정·파인튜닝·자체 서버 실행이 가능하다.

로컬 모델

클라우드 API 대신 개인 PC, 서버 등 사용자의 장치에서 직접 실행하는 모델 (Ollama, vLLM 등 활용).

Dense 모델과 MoE(Mixture of Experts)

Dense 모델

- 모든 파라미터가 항상 동작
- 구조가 단순하고 예측 가능성이 높음
- 계산 비용이 큼

예시:

- GPT 초기 계열
- Llama 일부 모델
- Gemma 일부 모델

MoE(Mixture of Experts)

- 여러 전문가(Expert) 중 일부만 활성화
- 필요한 영역만 선택적으로 계산
- 더 큰 모델을 상대적으로 낮은 비용으로 운영 가능
- 최근 대형 모델들이 많이 채택
- 속도와 비용 효율 개선 목적

파라미터(Parameter)

모델 내부의 학습된 숫자 값.

일반적으로 파라미터 수가 많을수록 더 복잡한 패턴을 학습할 수 있다.

토큰(Token)이란?

- LLM이 문장을 처리하는 최소 단위
- 반드시 단어 기준은 아님
- 글자, 단어 일부, 기호 단위로 나뉠 수 있음

예시 (내부적으로 여러 토큰으로 분리 가능)

- 안녕하세요
- ChatGPT
- `System.out.println()`

- 대부분의 비용과 속도는 토큰 기준으로 계산
- **입력 토큰** (Input Token)
- **출력 토큰** (Output Token)
- **컨텍스트 윈도우** (Context Window) 역시 토큰 기준

컨텍스트 윈도우(Context Window)

모델이 한 번에 기억하고 처리할 수 있는 최대 토큰 길이.
길수록 긴 문서와 대화를 다룰 수 있음.

모델(Model)과 SOTA

모델(Model)이란?

- 학습된 AI 자체
- 데이터와 파라미터를 기반으로 동작
- 서비스는 같은 모델이라도 다르게 구성 가능

모델마다 다른 특성:

- 속도, 비용, 추론 능력, 코드 생성 능력
- 다국어 성능, 이미지 처리 능력, 컨텍스트 길이

추론(Reasoning)

단순 암기 수준이 아니라 여러 단계를 거쳐 문제를 해결하는 능력.

SOTA(State Of The Art)

- 특정 시점 기준 가장 뛰어난 성능
- 논문, 벤치마크, 리더보드 기준으로 평가
- 매우 빠르게 바뀜

예시:

- 가장 높은 코딩 성능 모델
- 가장 긴 컨텍스트 모델
- 가장 빠른 응답 속도 모델
- 가장 저렴한 모델

벤치마크(Benchmark)

모델 성능을 비교하기 위한 평가 문제 세트.

오픈소스 모델과 로컬 모델



오픈소스 모델

- 모델 구조와 가중치(weights)를 공개
- 누구나 다운로드 가능
- 수정 및 재배포 가능한 경우도 많음

예시: Llama, Qwen, Gemma, DeepSeek



로컬 모델 (Local Model)

- 자신의 컴퓨터나 회사 서버에서 직접 실행
- 인터넷 없이 실행 가능
- 데이터 유출 위험 감소 및 기업 내부 문서 처리에 유리

단점:

- GPU 비용 필요
- 성능 저하 가능, 운영 복잡도 증가

GPU (Graphics Processing Unit)

대량 병렬 연산에 특화된 하드웨어. 딥러닝과 LLM 학습·추론에 핵심적으로 사용.

대표적인 생성형 AI 서비스



ChatGPT

- OpenAI 서비스
- 가장 대중적인 생성형 AI 서비스 중 하나
- 텍스트, 이미지, 음성, 코드 지원



Claude

- Anthropic 서비스
- 긴 문맥 처리와 안정성에 강점
- 문서 분석, 코드 작업에서 많이 사용



Gemini

- Google 서비스
- Google 생태계와 강한 연결
- 검색, 문서, 영상 이해 등 멀티모달 강화

멀티모달 (Multimodal)

텍스트뿐 아니라 이미지·음성·영상 등 여러 형태의 데이터를 함께 처리하는 방식.

생성형 AI 사용의 3개 층위 (1/3)

1. 서비스 / 애플리케이션 계층

최종 사용자가 직접 사용하는 영역. ChatGPT처럼 대화형 서비스를 사용하거나 기존 서비스에 AI 기능을 추가합니다.

예시

- 챗봇, 검색, 번역
- 회의 요약, 고객 응대
- 디자인 생성

핵심 가치

- 새로운 사용자 경험 제공
- 기존 업무 자동화
- 콘텐츠 생성 속도 향상

SaaS (Software as a Service)

클라우드 환경에서 호스팅되는 소프트웨어를 인터넷을 통해 제공받아 사용하는 서비스 모델.

PC에 직접 설치할 필요 없이 웹 브라우저 등을 통해 구독 형태로 이용하는 것이 일반적.

생성형 AI 사용의 3개 층위 (2/3)

2. API / Workflow / Protocol / Agent 계층

LLM을 직접 연결하여 시스템 구축. 여러 도구와 모델을 조합하여 자동화 및 생산성 향상을 목적으로 합니다.

예시 및 도구

- 생성형 AI API
- LangChain / LangGraph / SpringAI
- Claude Code / Codex
- n8n / dify

가능한 작업

- 여러 단계 자동화
- 문서 검색 후 답변
- 코드 자동 수정 및 브라우저 조작
- 슬랙/메일 연동

Agent (에이전트)

목표를 달성하기 위해 스스로 여러 행동을 수행하는 AI 시스템.

Workflow / API

여러 작업 단계를 연결한 흐름 / 프로그램끼리 연결하기 위한 인터페이스.

하네스 엔지니어링

AI 모델이 실제 환경에서 안정적이고 효율적으로 작동하도록 제어하는 기술.

MCP (Model Context Protocol)

AI 모델이 외부 도구에 안전하고 표준화된 방식으로 접근하는 개방형 프로토콜.

생성형 AI 사용의 3개 층위 (3/3)

3. 인프라 (Infrastructure) 계층

모델을 실제로 운영하는 영역. 학습, 배포, 서빙, 최적화를 담당하며 비용, 성능, 보안 문제와 직접 연결됩니다.

예시

- Ollama, vLLM
- AWS Bedrock
- GPU 서버
- 파인 튜닝, KV 캐시

주요 이슈

- GPU 비용 및 응답 속도
- 동시 사용자 처리
- 개인정보 보호 및 내부망 운영

서빙 (Serving)

학습된 모델을 실제 사용자 요청에 응답하도록 운영하는 과정.

생성형 AI 트렌드 (1/2)

모델 선택의 기준

- 어떤 모델이 더 좋은가?를 고민하기 보단 본인에 상황에 맞는 모델을 지속적으로 찾아가야 함
- 모델을 만드는 여러 플레이어들이 있고, 1~2달 정도를 기준으로 계속 선두 플레이어가 앞치락뒤치락하는 모양새
- 일반적으로 **이해력 → 속도 → 비용 → 보안** 순으로 모델을 판단. 업종/상황에 따라 종종 보안이 모든 것에 우선하는 경우도 있음.

최신 기술 및 커뮤니티

GeekNews

- Hacker News 스타일의 기술/스타트업 뉴스 번역 및 요약 공유 커뮤니티
- 최신 AI 게시글, 오픈소스 프로젝트, 글로벌 AI 트렌드 및 토론을 가장 빠르게 접할 수 있음

요즘IT

- 현업 기획자, 개발자, 디자이너들이 작성하는 실무 중심의 IT 아티클 플랫폼
- AI 툴 도입 사례, 프롬프트 엔지니어링 등 기업 현장의 생생한 AI 활용기를 확인할 수 있음

생성형 AI 트렌드 (2/2) - 리더보드/랭킹

Artificial Analysis

- 다양한 LLM의 성능, 가격, 응답 속도를 정량적으로 비교 분석하는 플랫폼
- 프로젝트 예산과 요구 성능에 맞춰 가성비 및 속도가 가장 뛰어난 AI 모델을 선택할 때 유용
- 실제 체감 성능과 벤치마크 점수가 일치하지 않는 경우가 다수

Arena AI

- 블라인드 테스트로 여러 모델과 대화해보고 직접 승자를 투표하는 클라우드소싱 기반 리더보드
- 실제 인간이 체감하는 AI의 자연스러움과 답변 품질 순위를 파악할 수 있음
- 서비스 구독/비용 지불/복잡한 세팅 없이 모델 테스트 가능
- AI 업체들의 마케팅 수단으로 활용되기도 함

OpenRouter

- 여러 AI 모델을 통합 API로 제공하는 플랫폼의 실제 API 호출 통계 및 랭킹 제공
- 전 세계 개발자들이 현재 실무 애플리케이션에서 어떤 모델을 가장 많이 사용하고 있는지 트렌드 확인 가능
- 가격 할인 중인 모델로 인해 순위가 왜곡되는 경우가 종종 있음

리더보드(Leaderboard)

모델 성능이나 선호도를 순위 형태로 보여주는 시스템.